

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»**

КУРСОВАЯ РАБОТА

по дисциплине

**«Фундаментальные и перспективные концепции искусственного
интеллекта»**

на тему:

**«Активное обучение сверточной нейронной сети для распознавания
дорожных знаков на наборе GTSRB»**

Студент: Горщенко Д. В.

Группа: М8О-105СВ-25

Москва 2026

РЕФЕРАТ

Курсовая работа посвящена разработке и исследованию процедуры активного обучения сверточной нейронной сети в задаче многоклассового распознавания дорожных знаков. В качестве предметной области выбран набор German Traffic Sign Recognition Benchmark (GTSRB), содержащий изображения 43 классов. Реализован сценарий pool-based active learning, в котором модель последовательно выбирает наиболее информативные неразмеченные изображения, получает их метки от имитируемого оракула и переобучается на расширенном размеченном множестве.

Рассмотрены критерии энтропии предсказания, минимального отступа между двумя наиболее вероятными классами и наименьшей уверенности. В качестве контрольной стратегии используется случайная выборка. Программная реализация выполнена на Python с применением PyTorch, torchvision и scikit-learn. Предусмотрены воспроизводимое разбиение данных, независимый тестовый набор, фиксация параметров запуска и сохранение метрик accuracy и macro-F1 по раундам.

Ключевые слова: активное обучение, компьютерное зрение, сверточная нейронная сеть, классификация изображений, GTSRB, дорожные знаки, неопределенность, энтропия, PyTorch.

СОДЕРЖАНИЕ

РЕФЕРАТ	2
ВВЕДЕНИЕ	4
1 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ АКТИВНОГО ОБУЧЕНИЯ	6
1.1 Постановка задачи	6
1.2 Критерии неопределенности	7
1.3 Ограничения неопределенности	8
2 НАБОР ДАННЫХ И ПОДГОТОВКА ЭКСПЕРИМЕНТА	9
2.1 Характеристика GTSRB	9
2.2 Предварительная обработка	9
2.3 Метрики и бюджет	11
3 ПРОГРАММНАЯ РЕАЛИЗАЦИЯ	12
3.1 Архитектура программного решения	12
3.2 Архитектура нейронной сети	12
3.3 Алгоритм активного обучения	13
3.4 Воспроизводимость и инженерные решения	13
4 ЭКСПЕРИМЕНТАЛЬНАЯ ПРОВЕРКА	15
4.1 План вычислительного эксперимента	15
4.2 Контрольный запуск	15
4.3 Правила интерпретации основного результата	16
4.4 Угрозы валидности	17
ЗАКЛЮЧЕНИЕ	18
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	19

ВВЕДЕНИЕ

Современные системы компьютерного зрения во многом опираются на обучение с учителем. Их качество обычно растет вместе с объемом размеченных данных, однако получение меток требует участия экспертов, времени и финансовых ресурсов. Для дорожных знаков цена ошибки разметки особенно заметна: близкие по внешнему виду классы различаются числом, направлением стрелки или небольшим пиктографическим элементом, поэтому разметчик должен внимательно рассматривать каждый объект.

Активное обучение направлено на сокращение объема ручной разметки. В отличие от стандартной схемы, где обучающая выборка формируется заранее, активный алгоритм сам указывает, какие объекты следует разметить следующими. Базовая гипотеза состоит в том, что не все примеры одинаково полезны: объекты около границы решений способны изменить модель сильнее, чем уже уверенно распознаваемые изображения [1].

Задача распознавания дорожных знаков подходит для такого исследования по трем причинам. Во-первых, она является практически значимой частью систем помощи водителю и автономного транспорта. Во-вторых, GTSRB содержит 43 несбалансированных класса, вариативность освещения, масштаба и ракурса. В-третьих, многоклассовая классификация позволяет сравнить несколько критериев неопределенности и проследить, не концентрируется ли алгоритм на ограниченном наборе сложных классов.

Цель работы - разработать воспроизводимую процедуру активного обучения сверточной нейронной сети для распознавания дорожных знаков GTSRB и определить способ ее экспериментального сравнения со случайным отбором данных.

Объект исследования - процесс обучения модели компьютерного зрения при ограниченном бюджете разметки. Предмет исследования - стратегии выбора информативных изображений из неразмеченного пула по выходным вероятностям нейронной сети.

Для достижения цели решаются следующие задачи:

- проанализировать базовые сценарии и стратегии активного обучения;
- обосновать выбор GTSRB и подготовить схему предварительной обработки изображений;
- разработать компактную CNN, пригодную для многократного переобучения;
- реализовать стратегии entropy, margin, least confidence и random;
- организовать итерационный эксперимент с фиксированным бюджетом разметки;
- сохранять accuracy, macro-F1 и состав выбранных пакетов для последующего анализа.

Методы исследования включают анализ научных публикаций, вычислительный эксперимент, сравнительный анализ кривых обучения и статистическую интерпретацию результатов. Практическая значимость состоит в получении программного прототипа, который можно использовать как основу системы приоритизации данных для разметки.

1 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ АКТИВНОГО ОБУЧЕНИЯ

1.1 Постановка задачи

Пусть L обозначает небольшое размеченное множество, а U - большой пул изображений без доступных алгоритму меток:

$$L = \{(x_i, y_i)\}_{i=1}^{n_L}, U = \{x_j\}_{j=1}^{n_U}$$

Классификатор с параметрами θ обозначим f_θ . На каждом раунде модель обучается на L , затем функция запроса $a(x; f_\theta)$ оценивает информативность каждого x из U . Выбранный пакет Q передается оракулу, после чего пары (x, y) добавляются в L и исключаются из U .

В данной работе применяется pool-based сценарий. Он предполагает наличие полного пула неразмеченных объектов до начала эксперимента и соответствует распространенной практике разметки изображений [1]. Метки GTSRB физически доступны программе, однако процедура выбора к ним не обращается. Они считываются только для выбранных индексов и тем самым имитируют ответ эксперта.

Критерием эффективности является не только максимальная итоговая точность, но и качество при каждом фиксированном размере L . Сравнение выполняется по кривой learning curve, где по горизонтали отложено число размеченных изображений, а по вертикали - метрика на неизменной тестовой выборке.




Рисунок 1 - Цикл pool-based активного обучения

1.2 Критерии неопределенности

Вероятность класса c для изображения x получается применением softmax к логитам z модели:

$$p_{\theta}(y = c|x) = \frac{\exp(z_c)}{\sum_{k=1}^C \exp(z_k)}$$

Стратегия наименьшей уверенности назначает объекту следующую оценку информативности:

$$a_{LC}(x) = 1 - \max_{c \in \{1, \dots, C\}} p_{\theta}(y = c|x)$$

Чем меньше максимальная вероятность класса, тем выше приоритет запроса. Стратегия минимального отступа использует две наибольшие вероятности $p_{(1)}$ и $p_{(2)}$:

$$a_M(x) = -p_{(1)}(x) - p_{(2)}(x)$$

Малый разрыв означает, что модель колеблется между двумя классами. Отрицательный знак позволяет сортировать все стратегии по убыванию единой оценки информативности. Энтропийная стратегия учитывает все распределение вероятностей:

$$a_H(x) = - \sum_{c=1}^C p_{\theta}(y = c|x) \log p_{\theta}(y = c|x)$$

Энтропия достигает максимума, когда вероятности классов близки друг к другу, и минимума при почти вырожденном распределении. Для многоклассовой задачи GTSRB она потенциально информативнее критерия, зависящего только от одного или двух классов.

Случайная стратегия выбирает пакет равновероятно из U и служит обязательной контрольной линией. Активный метод считается полезным, если при одинаковом бюджете разметки он устойчиво превосходит random в нескольких независимых запусках, а не только в одной удачной инициализации.

Стратегия	Оценка	Интерпретация	Особенность
Least confidence	$1 - \max(p)$	Нет уверенного класса	Использует только максимум
Margin	$-(p(1) - p(2))$	Два класса близки	Чувствительна к границе пары классов
Entropy	$-\sum p \log p$	Распределение размыто	Учитывает все 43 класса
Random	Случайное число	Контрольная стратегия	Не зависит от модели

1.3 Ограничения неопределенности

Высокая неопределенность не всегда означает высокую полезность. Модель может выбирать выбросы, изображения с сильным шумом или множество почти одинаковых кадров. Поэтому в промышленных системах критерий неопределенности часто дополняют оценкой репрезентативности, ограничением разнообразия пакета или стоимостью аннотации [2].

Вероятности современных нейронных сетей могут быть плохо калиброваны. Softmax способен выдавать высокую уверенность даже на нетипичных изображениях. В данной работе это ограничение фиксируется как угроза валидности; перспективным развитием являются температурная калибровка, ансамбли и Monte Carlo dropout [4].

Важен также холодный старт. Если начальное L не представляет часть классов, модель не может надежно оценить их границы. Поэтому начальный набор формируется стратифицированно: при наличии данных выбирается одинаковое число объектов каждого класса. Такой подход использует минимальную информацию о классах на этапе проектирования эксперимента, но не раскрывает метки остального пула стратегии запроса.

2 НАБОР ДАННЫХ И ПОДГОТОВКА ЭКСПЕРИМЕНТА

2.1 Характеристика GTSRB

German Traffic Sign Recognition Benchmark был представлен как многоклассовое соревнование IJCNN 2011. Исходный набор содержит более 50 тыс. изображений дорожных знаков, относящихся к 43 классам, причем частоты классов несбалансированы. В torchvision доступны стандартные части train и test.

Изображения различаются пространственным разрешением, яркостью, контрастом, степенью размытия и положением знака в кадре. Набор включает последовательности кадров одного физического знака, что требует осторожности при случайном разбиении: похожие изображения могут оказаться по разные стороны внутреннего train/validation. В данной учебной реализации официальная test-часть остается полностью независимой, а validation выделяется только из train.

Классы включают ограничения скорости, запрещающие, предписывающие, предупреждающие и информационные знаки. Некоторые пары отличаются лишь числовым значением. Это повышает требования к сохранению мелких деталей при масштабировании и объясняет выбор входного разрешения 48 x 48 вместо минимального 32 x 32.

Свойство	Значение в проекте
Тип задачи	Многоклассовая классификация изображений
Количество классов	43
Обучающая часть	GTSRB train; источник пула L и U
Тестовая часть	GTSRB test; не используется при выборе запросов
Размер входа	3 x 48 x 48
Основные метрики	Accuracy и macro-F1

2.2 Предварительная обработка

Все изображения приводятся к размеру 48 x 48 и преобразуются в тензор. Затем выполняется поканальная нормализация с фиксированными средними и

стандартными отклонениями. Одинаковая нормализация применяется к обучающей, валидационной и тестовой частям.

Только в обучающем режиме используются небольшие геометрические и фотометрические преобразования: поворот до 10 градусов, сдвиг, масштабирование, изменение яркости и контраста. Горизонтальное отражение не применяется, поскольку оно способно изменить смысл знаков направления. Такая предметная оговорка важнее механического применения стандартного набора аугментаций.

Для честного сравнения стратегий начальное L, validation и полный U одинаковы. Каждая стратегия получает отдельную модель, которая переобучается с нуля на каждом раунде при контролируемом seed. Это увеличивает вычислительные затраты, но устраняет влияние различной истории оптимизатора.

2.3 Метрики и бюджет

Ассигасу показывает долю правильных ответов и рассчитывается по формуле:

$$Accuracy = \frac{1}{N} \sum_{i=1}^N (y^{\wedge}_i = y_i)$$

Из-за дисбаланса классов ассигасу может скрывать неудовлетворительное качество на редких знаках. Поэтому дополнительно рассчитывается macro-F1: F1 вычисляется отдельно для каждого класса, затем результаты усредняются с одинаковым весом:

$$F_1^{macro} = \frac{1}{C} \sum_{c=1}^C \frac{2P_c R_c}{P_c + R_c}$$

Бюджет разметки определяется размером начального множества и числом запросов. В конфигурации по умолчанию выбирается до 20 изображений каждого присутствующего класса, затем выполняется 8 раундов по 600 объектов. При полном покрытии начальный бюджет составляет 860 изображений, а общий после восьми запросов - 5660 изображений. Эти параметры можно изменить через командную строку.

Для статистически обоснованного вывода полный эксперимент следует повторить не менее пяти раз с разными seed. В отчет включаются среднее значение и стандартное отклонение метрик. Один запуск демонстрирует работоспособность, но не доказывает устойчивого преимущества стратегии.

3 ПРОГРАММНАЯ РЕАЛИЗАЦИЯ

3.1 Архитектура программного решения

Проект реализован одним исполняемым модулем `active_learning_gtsrb.py`. Конфигурация запуска хранится в `dataclass RunConfig` и сохраняется в JSON. Такой подход делает эксперимент проверяемым: вместе с таблицей результатов остается точный набор гиперпараметров.

Функция `make_datasets` создает обучающий и тестовый наборы, а `initial_pool_split` формирует L, U и validation. Функция `train_model` каждый раунд создает новый экземпляр `TrafficSignCNN`. `Predict` возвращает вероятности и истинные метки только для оценки; `query_indices` для рабочего пула использует исключительно массив вероятностей и индексы.

После выбора запрошенные индексы записываются в `selected_samples.csv` вместе с номером раунда и ответом оракула. Этот журнал позволяет проверить распределение запросов по классам и выявить стратегию, которая чрезмерно концентрируется на небольшой группе знаков.

3.2 Архитектура нейронной сети

Классификатор содержит три сверточных блока с 32, 64 и 128 каналами. Каждый блок включает две свертки 3 x 3, batch normalization и ReLU, после чего пространственный размер уменьшается max pooling. Для входа 48 x 48 после трех операций max pooling формируется карта признаков 6 x 6. Ее размер вычисляется из параметра `image_size`, поэтому архитектура не использует неподдерживаемый на некоторых устройствах MPS вариант adaptive pooling.

Классификатор состоит из полносвязного слоя на 256 нейронов, ReLU, dropout 0,35 и выходного слоя на 43 класса. Компактная архитектура выбрана намеренно: в активном обучении модель приходится обучать много раз, поэтому тяжелая сеть резко увеличила бы стоимость эксперимента и затруднила воспроизводимость на обычном компьютере.

Оптимизация выполняется AdamW с начальной скоростью 0,001 и weight decay 0,0001. Для обучения используется многоклассовая перекрестная энтропия:

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(y_i | x_i)$$

Для полного исследования можно добавить scheduler и веса классов, но их влияние должно изучаться отдельно и одинаково для всех стратегий.

Компонент	Конфигурация	Назначение
Вход	3 x 48 x 48	Нормализованное RGB-изображение
Блок 1	Conv 32 x 2 + MaxPool	Низкоуровневые границы и цвета
Блок 2	Conv 64 x 2 + MaxPool	Комбинации локальных признаков
Блок 3	Conv 128 x 2 + MaxPool	Семантические детали знака
Голова	FC 256, Dropout 0,35, FC 43	Вероятности классов

3.3 Алгоритм активного обучения

1. Зафиксировать seed и сформировать одинаковые L, U и validation.
2. Обучить новый экземпляр CNN на текущем L.
3. Вычислить accuracy и macro-F1 на validation и официальной test-части.
4. Если бюджет исчерпан, завершить эксперимент.
5. Получить вероятности классов для каждого изображения U.
6. Рассчитать оценку информативности и выбрать верхние В объектов.
7. Запросить метки выбранных объектов у оракула, перенести их из U в L.
8. Перейти к следующему раунду и повторить шаги 2-7.

3.4 Воспроизводимость и инженерные решения

Генераторы random, NumPy и PyTorch инициализируются одним seed. Для CUDA отключается недетерминированный режим cuDNN. Устройство выбирается автоматически в порядке CUDA, Apple MPS, CPU. DataLoader использует pin_memory только на CUDA.

Сценарий поддерживает ограничения `max_train_samples` и `max_test_samples` для учебных запусков. Отдельный флаг `smoke-test` заменяет GTSRB синтетическим FakeData и проверяет полный тракт от формирования пула до CSV и графика без сетевой загрузки. Результаты `smoke-test` не интерпретируются как качество распознавания дорожных знаков.

Программа сохраняет промежуточные данные в открытых форматах CSV, JSON и PNG. Это позволяет анализировать результат внешними средствами и исключает зависимость курсовой работы от конкретной интерактивной среды.

4 ЭКСПЕРИМЕНТАЛЬНАЯ ПРОВЕРКА

4.1 План вычислительного эксперимента

Основной эксперимент сравнивает entropy, margin и random при одинаковом бюджете, начальном множестве, архитектуре и числе эпох. Стратегия least confidence доступна в программе как дополнительный вариант. На каждом раунде фиксируются размер L , validation accuracy, validation macro-F1, test accuracy и test macro-F1.

Независимая test-часть используется только для построения итоговой кривой и не влияет на обучение, раннюю остановку или выбор пакета. Для выбора гиперпараметров предназначена validation-часть. Такое разделение снижает риск подстройки процедуры под тестовые метки.

Корректный итоговый отчет должен содержать кривые среднего качества по нескольким seed и доверительные интервалы. Дополнительно полезно вычислить площадь под кривой качества по бюджету разметки и число меток, необходимое для достижения заранее заданного уровня accuracy.

Параметр	Основное значение
Seed	42; для серии: 42, 43, 44, 45, 46
Начальная разметка	20 объектов на класс
Число раундов	8
Размер запроса	600 изображений
Эпох на раунд	8
Batch size	128
Стратегии	entropy, margin, random

4.2 Контрольный запуск

До загрузки полного GTSRB выполняется smoke-test на FakeData. Его цель - подтвердить отсутствие ошибок в создании пулов, обучении, запросе меток, расчете метрик и сохранении файлов. Поскольку изображения и классы синтетические и статистически не связаны, значения accuracy и macro-F1 не характеризуют распознавание дорожных знаков и не используются для проверки исследовательской гипотезы.

Стратегия	Раунд	L	Val acc.	Val F1	Test acc.	Test F1
entropy	0	40	0.027	0.001	0.013	0.001
entropy	1	60	0.027	0.002	0.037	0.002
random	0	40	0.027	0.001	0.013	0.001
random	1	60	0.027	0.001	0.037	0.002




Рисунок 2 - Техническая кривая контрольного запуска на FakeData

4.3 Правила интерпретации основного результата

Преимущество entropy или margin следует считать подтвержденным, если их средняя кривая выше random при большей части бюджетов, различие воспроизводится на нескольких seed, а выигрыш наблюдается не только по ассигасу, но и по macro-F1. Единичный выигрыш на одном раунде недостаточен.

Если активные стратегии хуже random на ранних раундах, возможной причиной является некалиброванная модель в условиях малого L. Если macro-F1 отстает при приемлемой ассигасу, алгоритм, вероятно, предпочитает сложные объекты популярных классов. Это проверяется по selected_samples.csv.

Если entropy и margin дают близкие результаты, предпочтение можно отдать margin как более простой стратегии. Если entropy заметно выигрывает, это указывает на полезность учета полного распределения вероятностей для 43 классов. Отсутствие выигрыша также является содержательным результатом и требует анализа разнообразия запросов, выбросов и качества вероятностей.

4.4 Угрозы валидности

- корреляция соседних кадров одного знака может завышать качество внутренней validation-части;
- одна компактная CNN не позволяет обобщить вывод на все архитектуры;
- имитация оракула не учитывает ошибки и различную стоимость человеческой разметки;
- отбор по softmax зависит от калибровки модели;
- малое число повторов может сделать вывод чувствительным к seed;
- фиксированный размер пакета не отражает сценарии с адаптивным бюджетом.

ЗАКЛЮЧЕНИЕ

В курсовой работе разработана процедура pool-based активного обучения для многоклассового распознавания дорожных знаков GTSRB. Реализован полный цикл: формирование начального размеченного множества, обучение CNN, оценка неопределенности неразмеченных объектов, запрос пакета меток у имитируемого оракула и повторное обучение.

Программный модуль поддерживает энтропию предсказания, минимальный отступ, наименьшую уверенность и случайный отбор. Контрольная стратегия random делает возможной проверку основного тезиса активного обучения - достижения сопоставимого или более высокого качества при меньшем числе размеченных изображений.

Для снижения методических ошибок официальная test-часть GTSRB не участвует в выборе объектов, стратегии стартуют с одинакового разбиения, а модель переобучается с нуля на каждом раунде. Наряду с accuracy рассчитывается macro-F1, что важно при несбалансированных классах. Все параметры, метрики и выбранные индексы сохраняются в воспроизводимых форматах.

Контрольный запуск на синтетических данных проверяет инженерную целостность конвейера, но не заменяет основной эксперимент на GTSRB. Для обоснованного количественного вывода предусмотрена серия запусков с несколькими seed. Перспективными направлениями являются выбор разнообразного пакета, глубокие ансамбли, BALD, калибровка вероятностей и учет стоимости разметки.

Таким образом, цель работы достигнута: создана воспроизводимая программная основа и строгий экспериментальный протокол для исследования активного обучения в практически значимой задаче компьютерного зрения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Settles B. Active Learning Literature Survey. Computer Sciences Technical Report 1648. Madison: University of Wisconsin-Madison, 2009. 67 p.
2. Cohn D., Ghahramani Z., Jordan M. Active Learning with Statistical Models // Journal of Artificial Intelligence Research. 1996. Vol. 4. P. 129-145. DOI: 10.1613/jair.295.
3. Lewis D. D., Gale W. A. A Sequential Algorithm for Training Text Classifiers // Proceedings of SIGIR. London: Springer, 1994. P. 3-12.
4. Gal Y., Islam R., Ghahramani Z. Deep Bayesian Active Learning with Image Data // Proceedings of the 34th International Conference on Machine Learning. 2017. Vol. 70. P. 1183-1192.
5. Stallkamp J., Schlipsing M., Salmen J., Igel C. The German Traffic Sign Recognition Benchmark: A Multi-Class Classification Competition // IJCNN 2011. IEEE, 2011. P. 1453-1460. DOI: 10.1109/IJCNN.2011.6033395.
6. Stallkamp J., Schlipsing M., Salmen J., Igel C. Man vs. Computer: Benchmarking Machine Learning Algorithms for Traffic Sign Recognition // Neural Networks. 2012. Vol. 32. P. 323-332.
7. Torchvision. GTSRB dataset documentation [Электронный ресурс]. URL: <https://pytorch.org/vision/stable/generated/torchvision.datasets.GTSRB.html> (дата обращения: 02.09.2026).
8. PyTorch documentation [Электронный ресурс]. URL: <https://pytorch.org/docs/stable/> (дата обращения: 02.09.2026).

ПРИЛОЖЕНИЕ

Полная реализация активного обучения находится на гитхабе -
<https://github.com/DenisAmell/active-learning/tree/main>